TUTORIAL PRÁTICO

OmniRoute

Um gateway local para vários provedores de IA

Instalação, configuração e integração — passo a passo

v3.8.50

POR QUE

O problema que ele resolve

SEM GATEWAY

- Uma chave por provedor, espalhada em vários arquivos
- Cota estourou? O trabalho para.
- Trocar de modelo = mexer no código
- Nenhuma visão de quanto se gastou

COM O OMNIROUTE

- Um único endereço local para tudo
- Failover automático entre provedores
- Trocar de modelo = mudar uma string
- Painel com consumo, erros e latência

COMO FUNCIONA

O caminho de uma requisição



A chave de cada provedor fica guardada no gateway — o cliente conhece apenas uma chave local.

Compatível com dois protocolos: o formato OpenAI (/v1/chat/completions) e o formato Anthropic — por isso ferramentas muito diferentes conseguem apontar para o mesmo endereço.

ANTES DE COMEÇAR

Onde encontrar o OmniRoute

Projeto de código aberto. Três endereços úteis — e nenhum deles é onde você vai usar a ferramenta.

Repositório

`github.com/diegosouzapw/OmniRoute`

Código, documentação e o histórico de versões. É a fonte para conferir o que mudou.

Pacote npm

`npmjs.com/package/omniroute`

Onde o npm baixa. Serve para checar qual é a versão mais recente publicada.

Seu painel

`http://localhost:20128`

O endereço que importa no dia a dia. Roda na sua máquina, não na internet.

Você não precisa clonar o repositório para usar. O npm baixa tudo — o GitHub serve para ler a documentação e acompanhar atualizações.

ETAPA 0

Pré-requisitos

A única exigência real é a versão do Node.js — e ela é específica.

22.22.2+

ou qualquer 24.x / 25.x / 26.x

Node 23 não serve

A faixa é descontínua de propósito: a 23 é uma versão ímpar, sem suporte de longo prazo.

```
node -v            # confere a versão instalada
winget install OpenJS.NodeJS.LTS   # se precisar instalar
```

Depois de instalar o Node, feche e reabra o terminal — só assim o PATH é atualizado.

ETAPA 1

Instalar e subir o servidor

1 Instalação global via npm

```
npm install -g omniroute
```

2 Executar

```
omniroute
```

3 Abrir no navegador

http://localhost:20128

Atenção

- O servidor vive enquanto a janela do terminal estiver aberta. Fechou, caiu.
- Ele escuta apenas em localhost — nada é exposto para a rede.
- Alternativa: Docker, se você preferir não depender do Node instalado.

ETAPA 2

Primeiro acesso

Senha padrão

CHANGEME

Troque na primeira sessão

O nome já diz. É uma senha pública, documentada, conhecida por qualquer pessoa que leia o repositório.

O que conferir assim que entrar

Idioma

O painel tem PT-BR no seletor do topo

Topologia

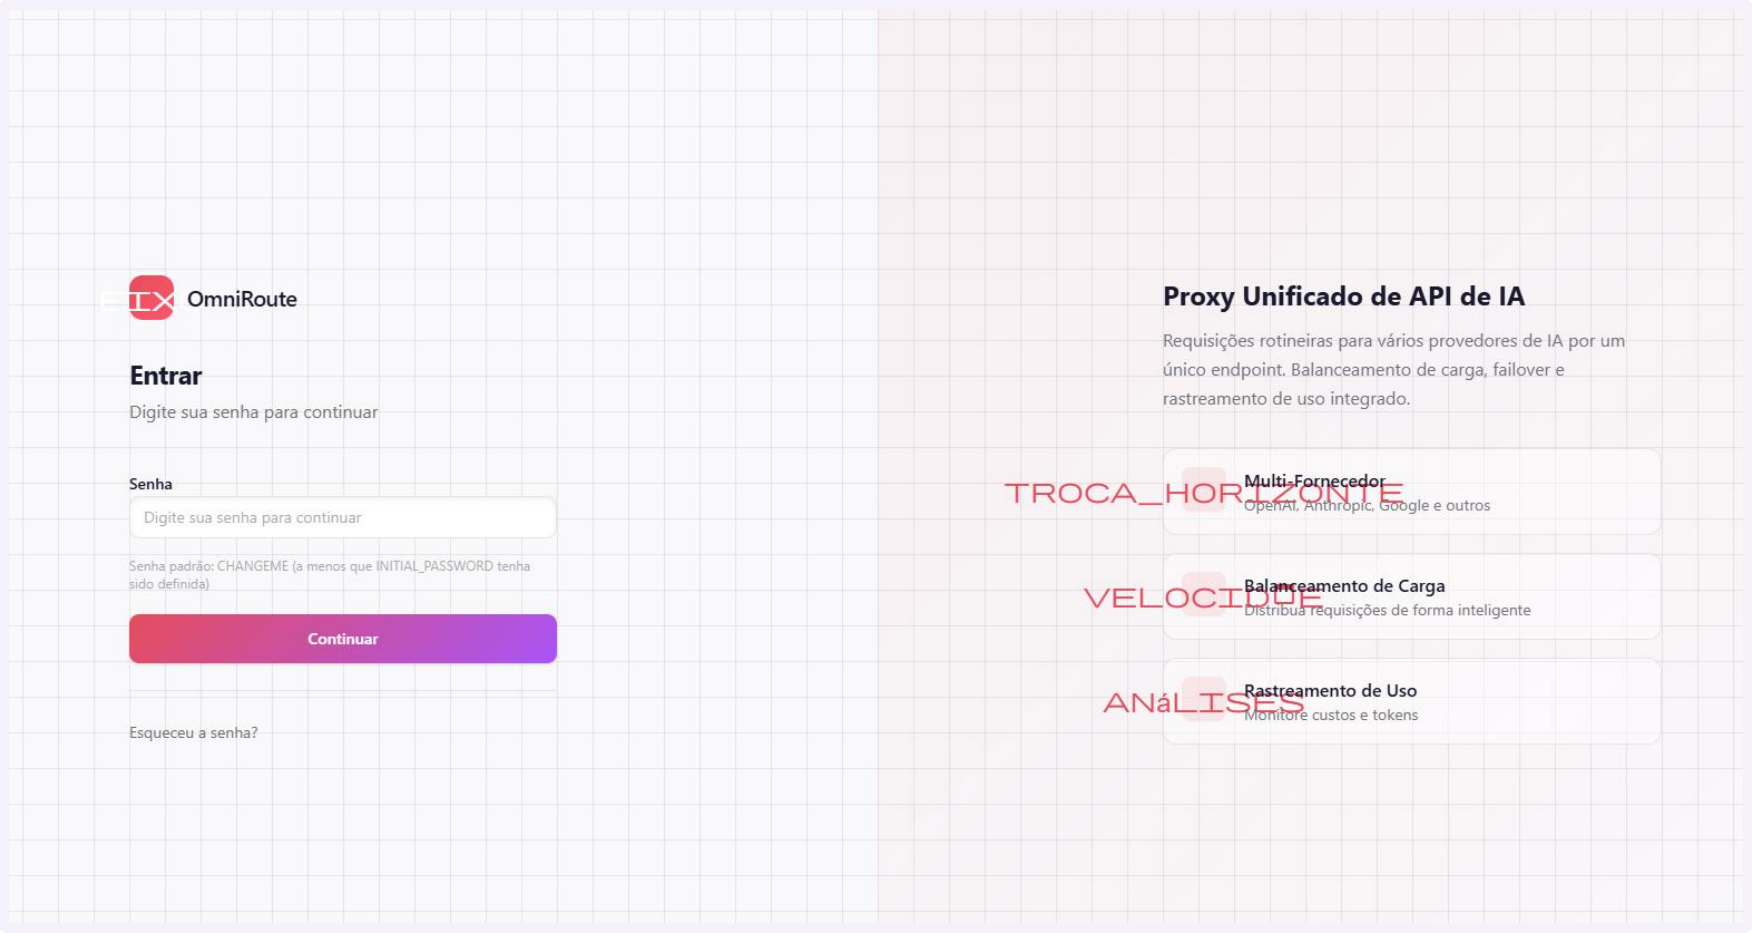
Vai mostrar "0 ativo" — é o esperado nesse momento

Banners

Os do topo são links de parceria; pode fechar

TELA REAL · 01

A tela de login



A própria tela informa a senha padrão: CHANGEME. Note que ela só muda se a variável INITIAL_PASSWORD tiver sido definida antes.

NAVEGAÇÃO

O mapa do painel

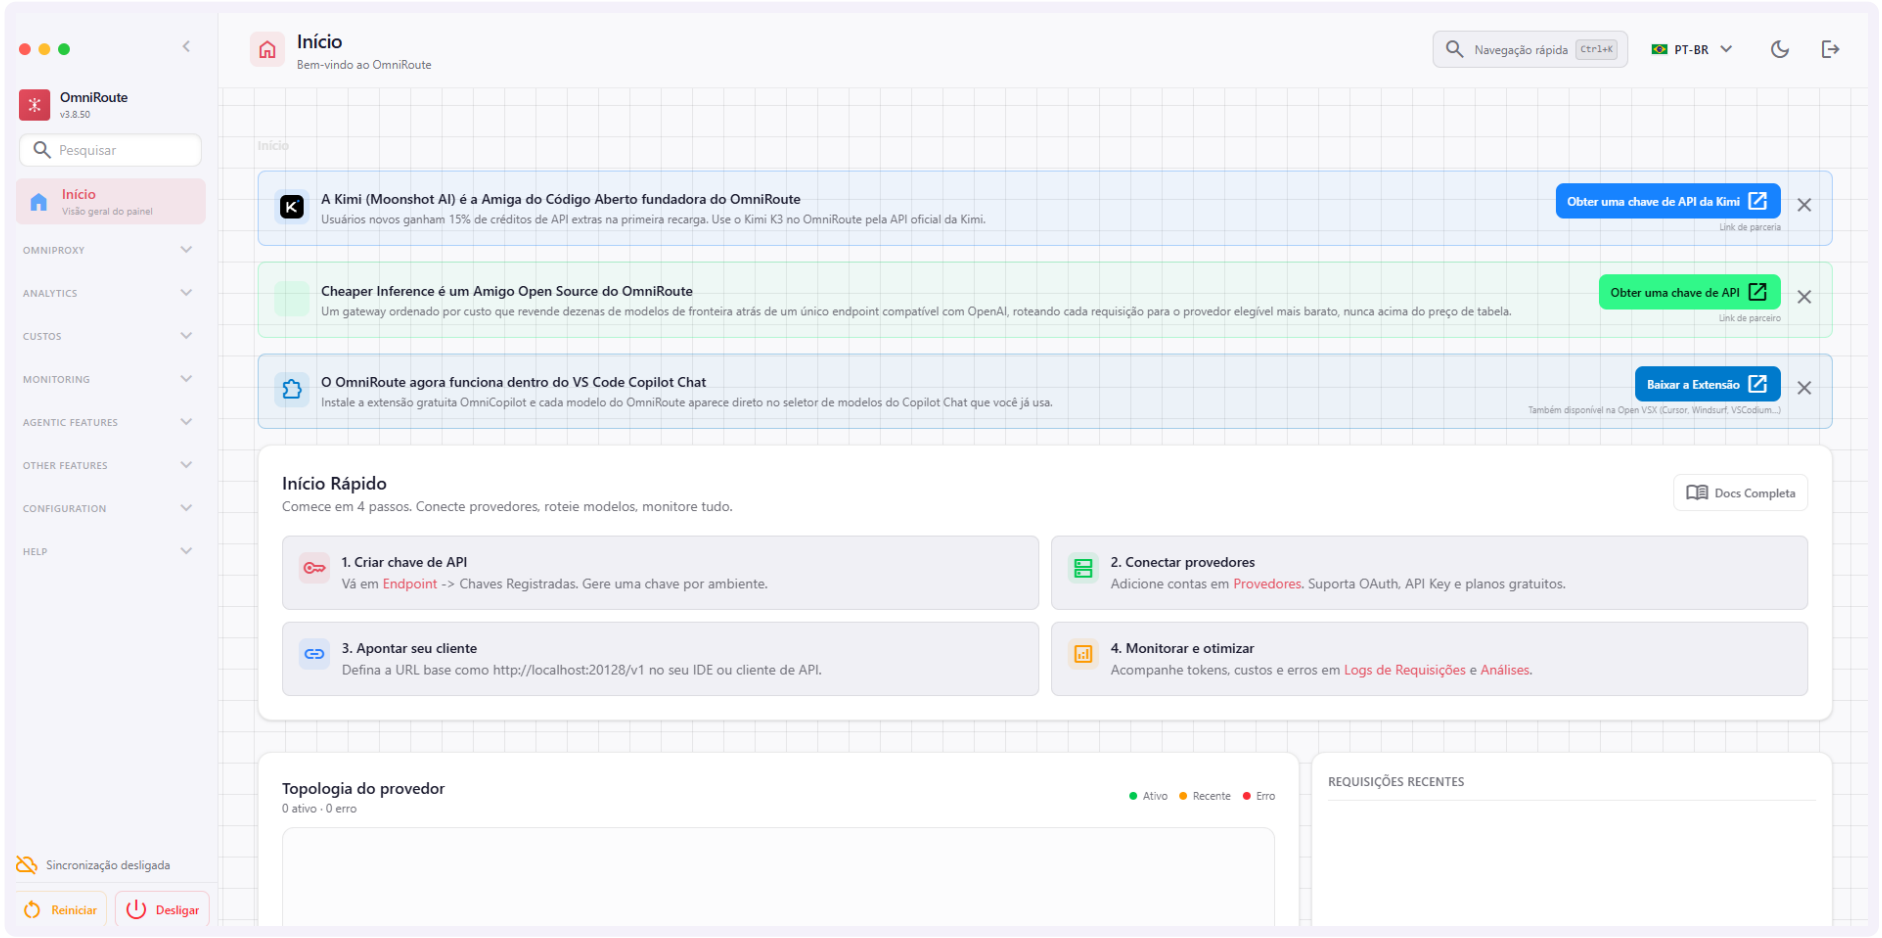
O menu da esquerda é longo. Estas são as seções que você realmente usa para pôr o gateway no ar.

Início	Visão geral. A "Topologia do provedor" é o seu termômetro: fora do zero significa que há rota funcionando.
OmniProxy → Endpoints	Os URLs de conexão que você vai colar nas ferramentas.
OmniProxy → Gerenciador API	Onde as chaves locais são criadas e revogadas.
OmniProxy → Provedores	O catálogo com os filtros. É aqui que se conecta e se testa.
OmniProxy → Combos	A cascata de failover. Combo Studio permite regras mais finas.
Analytics / Custos	Consumo por chave, tokens e latência. Vale olhar depois da primeira semana.
Configuration	Senha, idioma e ajustes gerais. Primeira parada depois do login.

Em destaque, as três telas do caminho mínimo: configurar a senha, conectar provedores, conferir na tela inicial.

TELA REAL · 02

O painel inicial



Repare em "Topologia do provedor: 0 ativo · 0 erro" — ainda não há nada conectado. Os três banners do topo são links de parceria e podem ser fechados.

ETAPA 3

Criar a chave de API local

Menu OmniProxy → Gerenciador API → Criar Chave de API

1

Aparece uma vez só

Depois de criada, a chave é mascarada. Copie na hora e guarde num gerenciador de senhas. Perdeu? Revogue e crie outra — não há recuperação.

2

Uma chave por ferramenta

Cada chave isola o rastreamento de consumo. Assim você vê quanto o VS Code gastou e quanto os seus scripts gastaram, separadamente.

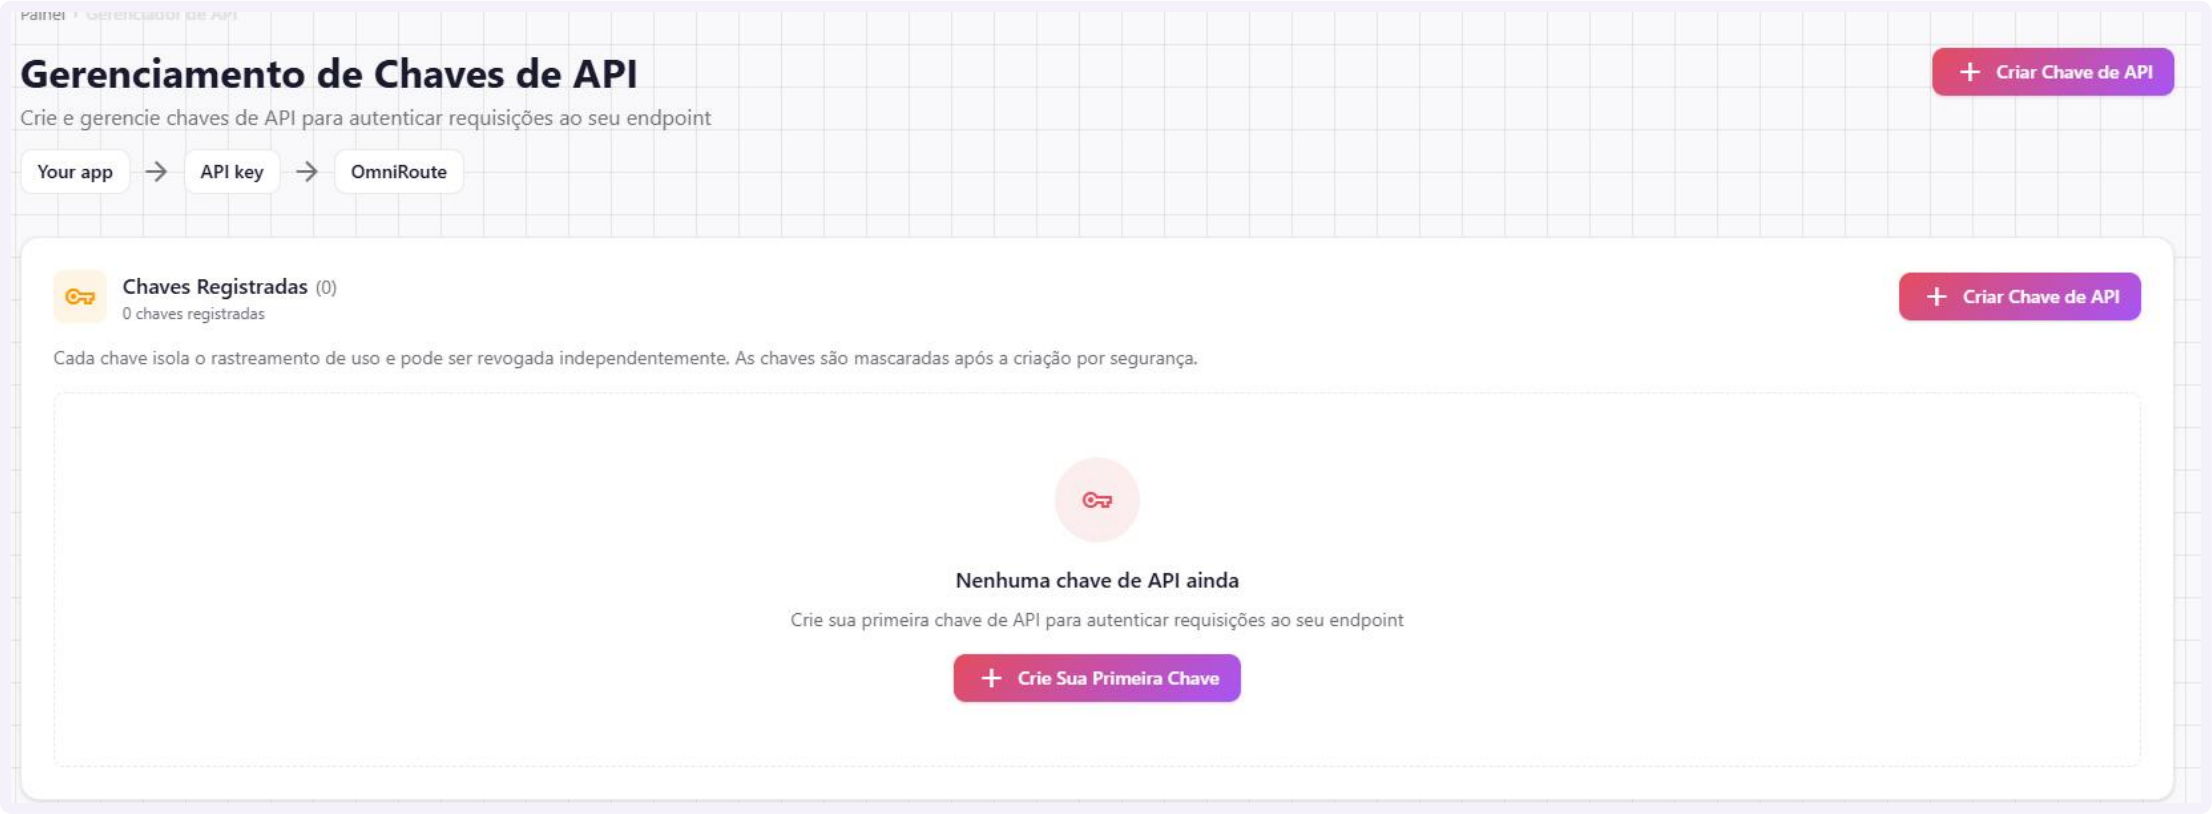
3

Nunca em texto compartilhado

Não cole a chave em chat, e-mail, issue ou slide. Em scripts, use variável de ambiente em vez de escrever o valor no arquivo.

TELA REAL · 03

Gerenciamento de chaves



O aviso está no próprio painel: as chaves são mascaradas após a criação. O diagrama do topo resume o fluxo — sua aplicação, a chave, o OmniRoute.

ETAPA 4

Conectar provedores

São 347 no catálogo. Os filtros coloridos do painel são o que torna a escolha viável.

13

Sem Auth

Funcionam na hora, sem cadastro

20

OAuth

Login na sua conta, token renovado sozinho

154

Plano gratuito

Free tier mediante cadastro no provedor

230

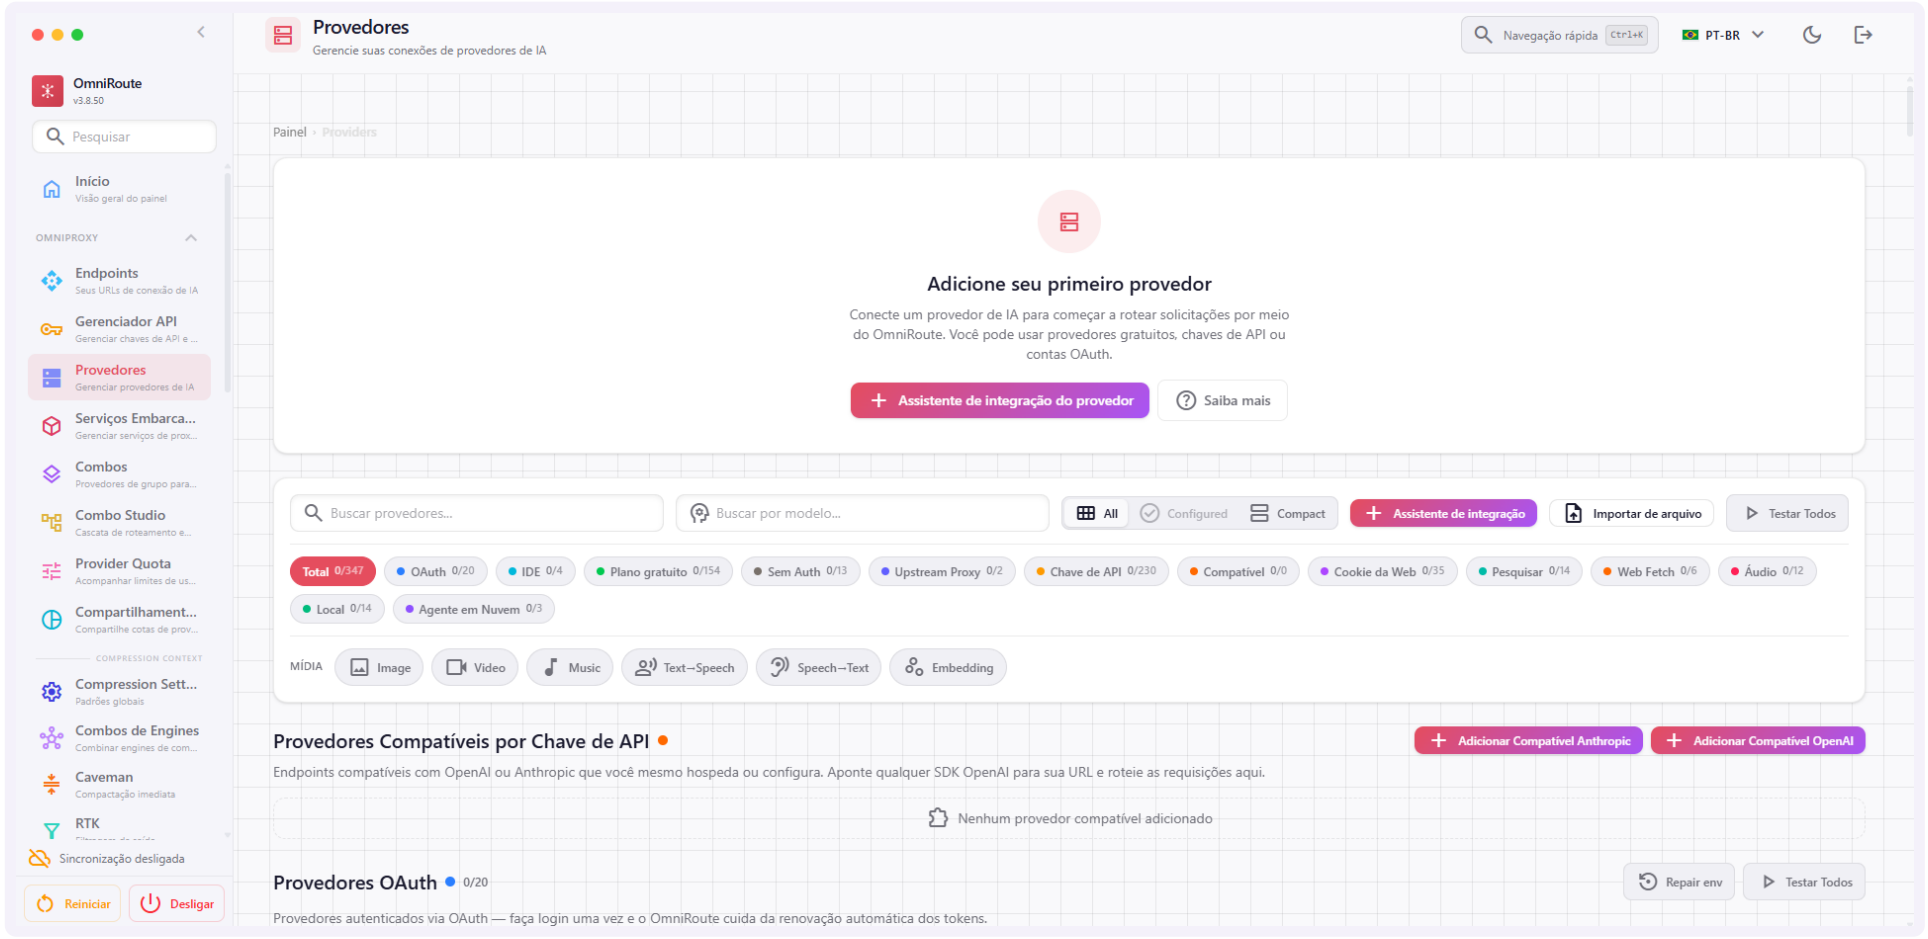
Chave de API

Você traz a sua chave paga

Comece pelo botão "Testar Todos". A disponibilidade real muda de semana para semana — conectar sem testar é conectar no escuro.

TELA REAL · 04

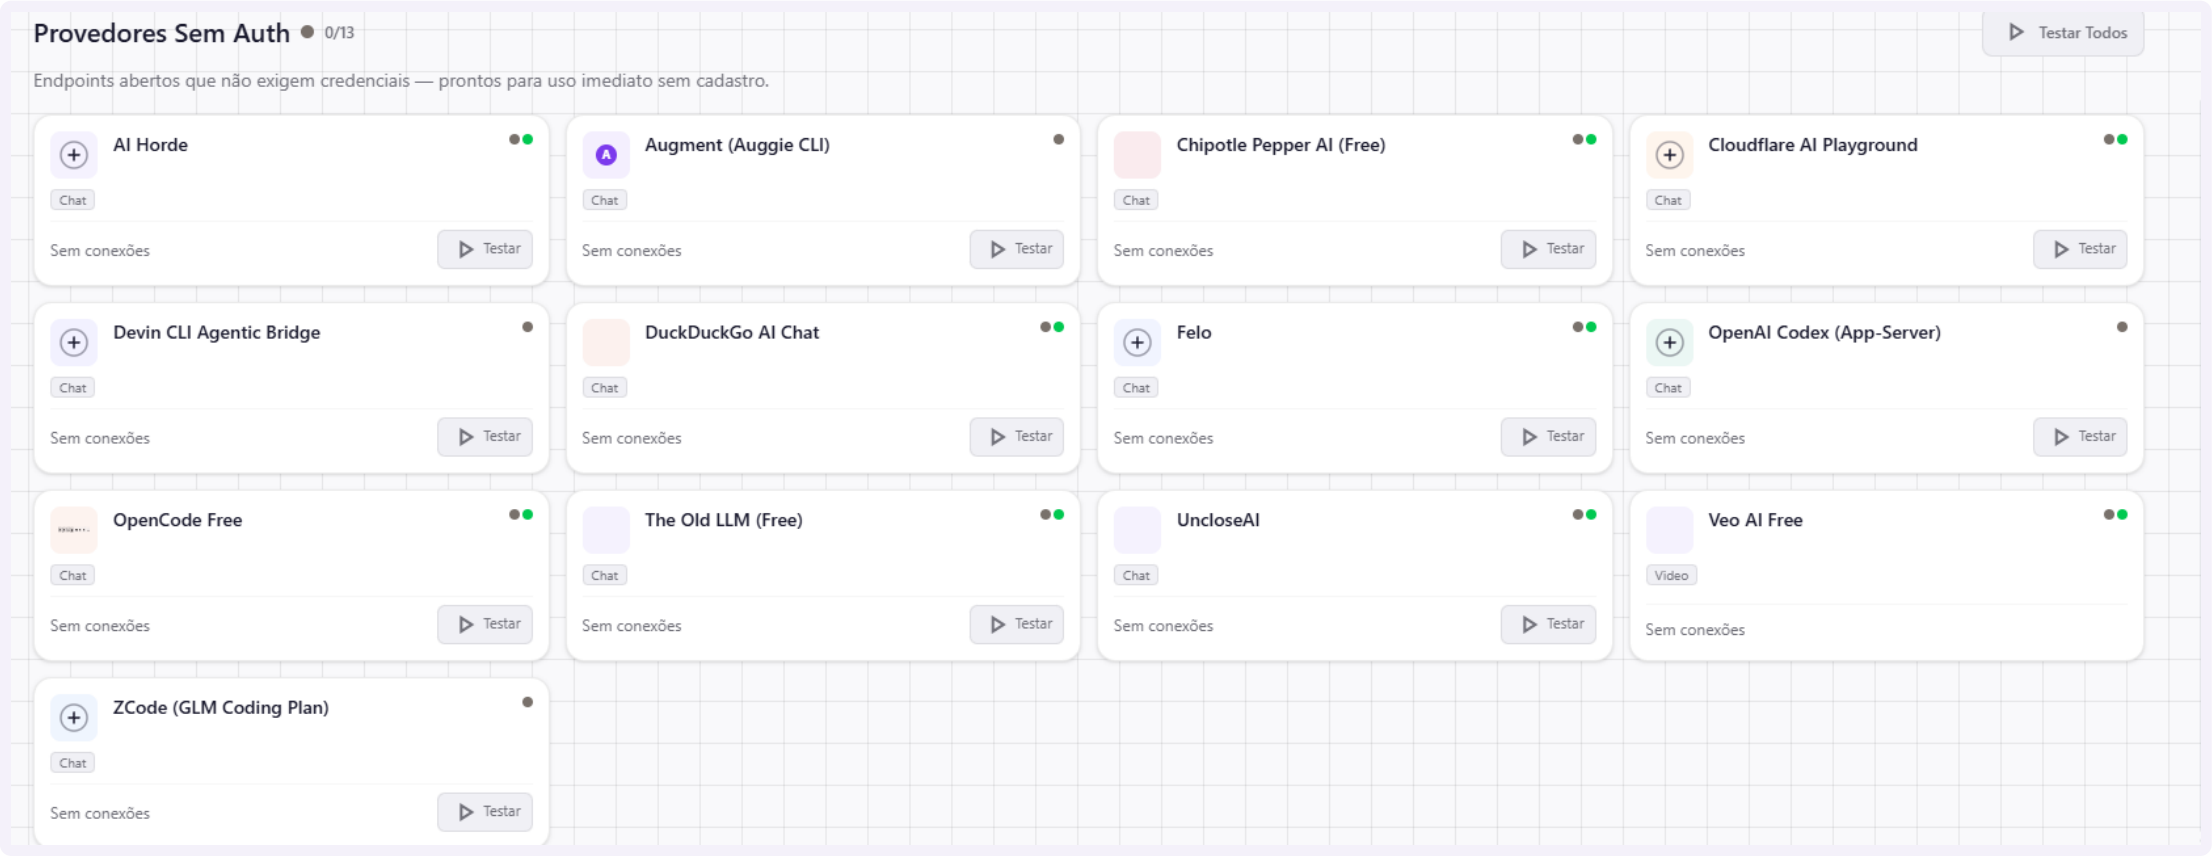
O catálogo e seus filtros



Os filtros coloridos são o atalho para navegar entre 347 provedores. O contador de cada um mostra quantos você já conectou daquele tipo.

TELA REAL · 05

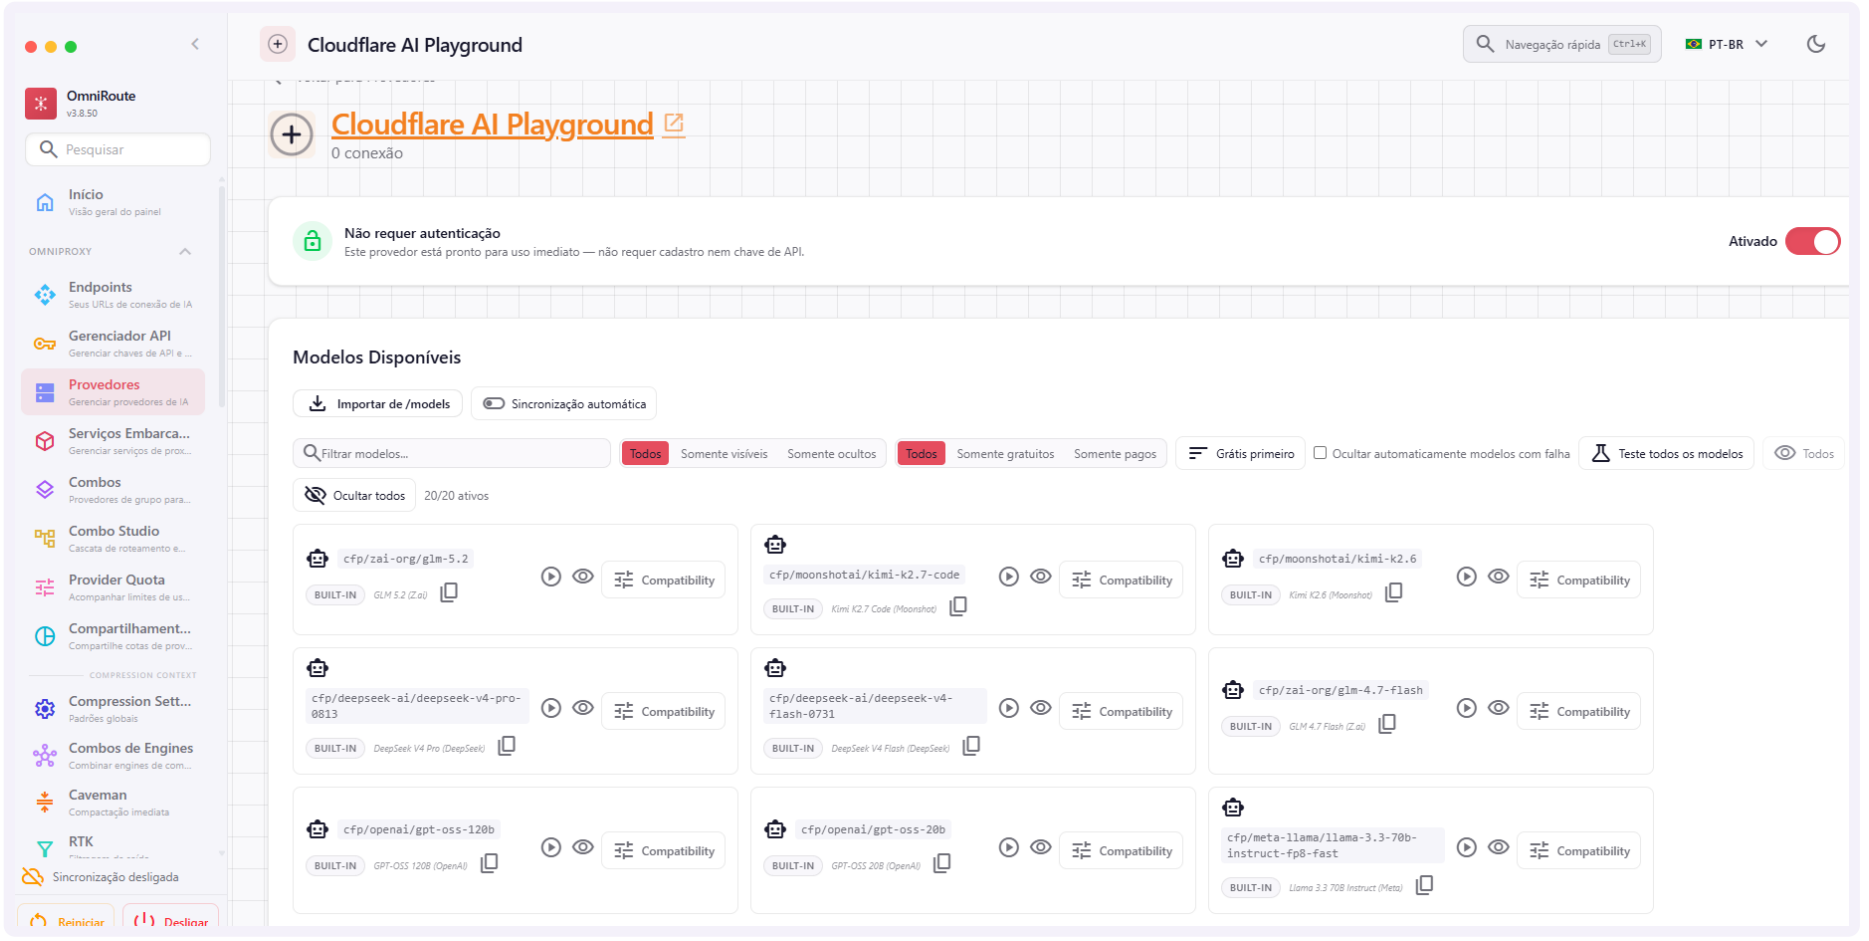
Os provedores sem autenticação



Dois pontos verdes indicam provedor saudável; um ponto cinza, indisponível. Clique em "Testar Todos" antes de escolher — a lista muda com frequência.

TELA REAL · 06

Dentro de um provedor



O aviso verde confirma que não há credencial a informar. Abaixo, os 20 modelos disponíveis — GLM, Kimi, DeepSeek, GPT-OSS, Llama — cada um com botão de teste.

CRITÉRIO

Nem todo provedor serve para tudo

A pergunta certa não é "funciona?", e sim "para onde vai o meu texto?".

Tudo bem para rascunho e teste

- Endpoints abertos, sem autenticação
- Computação voluntária distribuída
- Endpoints de chatbots corporativos usados fora do propósito

Podem sumir sem aviso e não oferecem garantia sobre o destino do prompt.

Exige conta sua e termos claros

- Trabalho de pesquisa e escrita de tese
- Qualquer dado de aluno
- Material não publicado ou sob sigilo

Provedores OAuth: você sabe com quem está falando e sob qual política.

ETAPA 5

Combos: onde mora o failover

Um combo é uma cascata ordenada de provedores por trás de um único nome.

Provedor A tenta primeiro

Provedor B cota estourou? assume

Provedor C caiu também? assume

Você continua trabalhando sem perceber a troca.

Combos prontos

`auto`	`equilíbrio geral`
`auto/coding`	`qualidade em código`
`auto/fast`	`menor latência`
`auto/cheap`	`menor custo`

Combo próprio criado em OmniProxy → Combos → Criar Combo é referenciado com o prefixo combo/ — por exemplo combo/modelos-gratuitos. Confirme sempre no botão de copiar do painel.

INDO ALÉM

Provedores com free tier e conta sua

É o degrau seguinte aos "Sem Auth": você cria a conta, gera a chave no site do provedor e cola no OmniRoute.

Groq

Inferência muito rápida em modelos abertos. Free tier generoso para uso individual.

OpenRouter

Agrega dezenas de modelos, vários com camada gratuita. Uma chave, muitos destinos.

Ollama

Roda modelos na sua própria máquina. Sem cota, sem rede — limitado pelo seu hardware.

Ao adicionar a conexão, marque "importar apenas modelos gratuitos" — sem isso o catálogo enche de modelos pagos que você pode acionar por engano.

Ollama merece atenção especial no seu caso: como roda local, é o único destino em que o prompt nunca sai da máquina — a escolha natural para material de tese e dado de aluno.

ECONOMIA

Compressão de contexto

OmniProxy → Compression Settings. Reduz o tamanho do que é enviado, esticando a cota gratuita.

RTK

Filtragem de saída. Comece no modo padrão — é o ajuste conservador.

Caveman

Compactação imediata do prompt. Modo completo no uso comum; ultra comprime mais, ao custo de nuance.

Ligue por último, e uma coisa de cada vez

Compressão mexe no que o modelo recebe, então pode degradar respostas em tarefas que dependem de detalhe — escrita acadêmica, revisão de código longo. Estabeleça primeiro que tudo funciona sem ela; depois ative e compare a qualidade.

ETAPA 6

Apontar suas ferramentas

Formato OpenAI

```
Base URL : http://localhost:20128/v1
Model    : auto
API key  : sua chave local
```

Formato Anthropic

```
{ "env": {
  "ANTHROPIC_BASE_URL": "http://localhost:20128",
  "ANTHROPIC_AUTH_TOKEN": "...",
  "ANTHROPIC_MODEL": "auto" } }
```

Teste antes de confiar: uma chamada a /v1/models lista tudo que o gateway enxerga — e revela a grafia exata de cada modelo e combo.

```
curl.exe http://localhost:20128/v1/models -H "Authorization: Bearer $env:OMNI_KEY"
```

VERIFICAÇÃO

Como saber que está mesmo roteando

Configurar não é o mesmo que funcionar. Estes três sinais fecham a prova.

1. **Abra uma sessão nova**

   A configuração só é lida na inicialização. Terminal aberto antes da edição continua com os valores antigos.

2. **Mande um "oi"**

   Uma mensagem trivial basta. O objetivo é gerar tráfego, não testar capacidade.

3. **Confira em Monitoring → Logs**

   A requisição aparece registrada, com o modelo que de fato respondeu. É aí que você descobre para onde seu texto foi.

O log é a única fonte honesta sobre qual provedor atendeu. Vale conferir antes de mandar qualquer coisa sensível.

DIAGNÓSTICO

Os quatro erros de sempre

`Invalid API key`	A chave veio com aspas, espaço ou quebra de linha do copiar/colar. Ou é um texto de exemplo que ficou no lugar do valor real.
`Connection refused`	A janela do terminal que rodava o servidor foi fechada. Reabra e execute omniroute de novo.
`Erro de parâmetro no PowerShell`	Foi usado curl em vez de curl.exe. No PowerShell, curl é apelido de outro comando.
`404 no endpoint Anthropic`	A base URL precisa ou não precisa do /v1 conforme o cliente. Se falhou sem, tente com — e vice-versa.

Regra geral: leia a mensagem inteira antes de mudar qualquer coisa. Um "Invalid API key" prova que o servidor está de pé, autenticando e respondendo — é meio caminho andado.

RESUMO

Do zero ao funcionando

1. **Conferir o Node**

   `node -v → precisa ser 22.22.2+ ou 24/25/26`

2. **Instalar**

   `npm install -g omniroute`

3. **Subir o servidor**

   `omniroute (deixe a janela aberta)`

4. **Entrar no painel**

   `localhost:20128 → senha CHANGEME → trocar`

5. **Criar a chave**

   `OmniProxy → Gerenciador API → copiar na hora`

6. **Testar provedores**

   `Provedores → filtro Sem Auth → Testar Todos`

7. **Conectar**

   `ative os que passaram no teste`

8. **Montar o combo**

   `Combos → cascata de failover → copiar o ID`

9. **Verificar o ID**

   `GET /v1/models → confirme a grafia exata`

10. **Apontar o cliente**

    `base URL + modelo/combo + chave`

Os passos 6, 9 e 10 são testes. Pular teste é o que transforma um problema de cinco segundos num problema de meia hora.

CASO PRÁTICO

Apontar o Claude Code para o gateway

A configuração vive em .claude/settings.local.json, dentro da pasta do projeto.

1. Criar a pasta e o arquivo (PowerShell)

```
New-Item -ItemType Directory -Force -Path ".\.claude"
```

2. Conteúdo do settings.local.json

```
{
  "env": {
    "ANTHROPIC_BASE_URL": "http://localhost:20128",
    "ANTHROPIC_AUTH_TOKEN": "sua-chave-local",
    "ANTHROPIC_MODEL": "auto"
  }
}
```

Duas pegadinhas

- A base URL aqui vai SEM /v1 — o SDK acrescenta o caminho. Deu 404? tente com.
- Comece com "auto" e só troque pelo seu combo depois de confirmar o ID.

Se a pasta ficar dentro de um serviço de nuvem sincronizado, lembre que esse arquivo carrega uma chave — e vai ser replicado.

NA PRÁTICA

O que a instalação real ensinou

O "+" não criava conexão

Provedor sem autenticação não tem credencial para guardar — o contador fica em zero por design. O que vale é a resposta da API, não o número na tela.

"Invalid API key" era boa notícia

O texto de exemplo tinha sido colado literalmente. Mas o erro provou que o servidor estava de pé e autenticando.

curl não é curl no PowerShell

É apelido de Invoke-WebRequest, com outra sintaxe. Use curl.exe — e guarde a chave numa variável de ambiente em vez de repeti-la.

A pasta .claude é protegida

Ferramentas remotas não escrevem nela. É proposital: é onde moram permissões e configuração. Criar essa pasta é tarefa de quem está na máquina.

Nenhum desses aparece na documentação. Aparecem quando alguém instala de verdade.

CHECKLIST

Está tudo de pé?

- ✓ Node em versão compatível e omniroute instalado
- ✓ Servidor rodando e painel abrindo em localhost:20128
- ✓ Senha padrão trocada
- ✓ Ao menos uma chave de API criada e guardada
- ✓ Provedores testados e conectados — topologia fora do zero
- ✓ Combo escolhido e identificador confirmado
- ✓ Cliente apontado e testado com uma chamada real

E lembre: o gateway roteia, mas quem decide o destino do seu texto é você.